INTELIGENCIA DE NEGOCIOS · PROYECTO FINAL

BI Vinilos y Témperas

Producción y paros de las líneas de envasado: de un Excel a un modelo dimensional, un tablero analítico en Power BI y un tablero operativo con alertas en Grafana

INTEGRANTES

Andrés Felipe Asprilla Pedroza
Jorge Andrés Grisales

REPOSITORIO

https://github.com/ISFLOWAAA/bi-vinilos

FECHA

1 de noviembre de 2026

Contenido

1. Resumen ejecutivo: hallazgos y recomendaciones
2. Usuarios, preguntas de negocio y catálogo de indicadores
3. Diagnóstico de la fuente de datos
4. Modelo dimensional
5. Diccionario de datos
6. ETL: del Excel al modelo estrella
7. Validacion del ETL
8. Base de datos: DDL, restricciones, índices y consultas
9. Power BI: tablero analitico para la gerencia
10. Grafana: monitoreo casi en tiempo real
11. Simulacion de datos hora a hora
12. Arquitectura de la solución
13. Power BI y Grafana: para qué sirve cada uno
14. Evolución: datos directos desde PLC y SCADA
15. Datos personales y seguridad de acceso
16. Repositorio y reproducción

1. Resumen ejecutivo: hallazgos y recomendaciones

Cifras del modelo cargado, del 2 de enero de 2022 al 28 de marzo de 2025: 5.138 jornadas, 37.934 horas programadas, 8.432 horas de paro y 325.266 pacas válidas.

1.1 El problema

La dirección revisa un informe mensual hecho a mano en Excel. No puede comparar años con facilidad, no sabe qué causas pesan más y los supervisores solo se enteran de un paro cuando ya pasó. Se construyó una solución que integra los datos en un modelo en estrella, con un tablero analítico en Power BI y uno operativo con alerta en Grafana.

1.2 Hallazgos

#	Hallazgo	Evidencia
1	**El OEE promedio mensual de las líneas está entre 55 % y 64 %**, lejos de la referencia mundial de 85 %.	2022: 63,8 % · 2023: 55,2 % · 2024: 58,0 % · 2025 (hasta marzo): 56,7 %
2	**La disponibilidad es la principal pérdida y baja cada año.**	87,0 % (2022) → 79,8 % → 69,3 % → 67,2 % (2025)
3	**Vinilos_2 es la línea más débil**, y Vinilos_3 y Vinilos_4 las mejores.	OEE promedio: Vinilos_2 49,4 % · Vinilos_1 53,7 % · Vinilos_3 64,7 % · Vinilos_4 65,2 %
4	**Cinco causas concentran el 79 % de las horas de paro**, y ninguna es una falla de máquina.	Aseo y alimentación [16] 23,7 % · Ajuste operativo [05] 21,5 % · Derrames [06] 18,3 % · Pausa activa [17] 8,5 % · Cambio de referencia [07] 7,4 %
5	**Las fallas electromecánicas pesan solo el 3,8 %** del paro (323 h). El problema no es principalmente de mantenimiento correctivo.	MTTR de 0,3 a 0,9 h por falla
6	**El 66 % del paro (5.540 h) es no programado**, es decir, evitable.	Paro programado: [15], [16], [17], [04], [18]
7	**Dentro del ajuste operativo, el sistema de dosificación de pintura es el mayor responsable:** 43 % de las horas de ajuste.	784 de 1.813 h

Una advertencia sobre el hallazgo 2

Parte de la caída de disponibilidad puede deberse a que **desde 2023 se registran más paros**, y no solo a un deterioro real. Por ejemplo, el cambio de referencia [07] suma 11 horas en 2022 y 378 en 2024. Antes de concluir que la planta empeoró, hay que confirmar con mantenimiento si la forma de registrar cambió. Lo mismo aplica al rendimiento: la velocidad de referencia se calcula por año, por lo que el rendimiento no es comparable entre años y solo sirve para comparar máquinas dentro del mismo periodo.

1.3 Recomendaciones

#	Recomendación	Impacto esperado
1	**Atacar los paros no programados de proceso** (ajustes, derrames, cambios de referencia) con un plan de estandarización: procedimientos de ajuste, listas de verificación y cambio rápido de referencia.	Reducir esas causas en 20 % recuperaría unas **1.100 horas, cerca de 3 puntos de disponibilidad** (escenario ilustrativo: 5.540 h × 20 % = 1.108 h sobre 37.934 h)
2	**Priorizar el sistema de dosificación de pintura** (ajuste y falla): es la causa individual más grande dentro del ajuste operativo y el primer subsistema en fallas.	Concentra 784 h de ajuste y 117 h de falla

#	Recomendación	Impacto esperado
3	**Revisar la línea Vinilos_2** (OEE 49 %, disponibilidad 72 %): el mejor candidato para un piloto de mejora y de medición automática.	Es la línea con más margen de mejora
4	**Mejorar la captura de datos:** turno obligatorio, guardar la meta por hora, validar la cifra al digitar (pacas contra unidades), registrar producto no conforme.	Hoy 47 % de las jornadas no tienen turno y no se puede medir la calidad real
5	**Usar el tablero de Grafana en los turnos** y acordar quién responde cuando salta la alerta de paro prolongado.	Pasar de enterarse al final del mes a reaccionar en el turno
6	**Evolucionar a medición automática** con PLC o SCADA, empezando por un piloto en una línea.	Datos en segundos, sin transcripción manual (ver `evolucion_plc_scada.md`)

1.4 Limitaciones que el lector debe conocer

- La **velocidad de referencia** es un percentil 90 del histórico y no la velocidad nominal de la máquina; por eso el OEE puede pasar de 100 % en algún mes.
- La **calidad** es una aproximación (horas de reproceso y materia prima defectuosa), porque la fuente no registra producto no conforme.
- Las **11 jornadas con pacas imposibles** (Vinilos_1, julio de 2023) se anularon en el cálculo de rendimiento y quedaron documentadas.
- Los datos de **2025 llegan solo hasta marzo**.

2. Usuarios, preguntas de negocio y catálogo de indicadores

2.1 Usuarios y preguntas de negocio

Usuario	Necesidad	Preguntas que debe poder responder	Herramienta
Alta dirección y jefes de área	Decidir inversiones y planes de mantenimiento	¿Cómo evoluciona el OEE por máquina y año? ¿Qué máquina rinde menos? ¿Qué causas concentran el 80 % de las horas perdidas? ¿Mejoramos frente al año anterior?	Power BI
Coordinador de mantenimiento	Priorizar intervenciones y presentar el informe mensual	¿Qué fallas (código 01, 03, 05) y qué subcódigos pesan más? ¿Cuánto tarda en promedio una reparación (MTTR) y cada cuánto falla una máquina (MTBF)? ¿Qué parte del paro es evitable?	Power BI y Grafana
Supervisores de producción	Reaccionar durante el turno	¿Qué máquinas están paradas ahora? ¿Cuánto llevan paradas? ¿Cómo va la producción del turno frente a la meta?	Grafana
Planeación	Programar referencias y cambios	¿Cuánto tiempo se pierde en cambios de referencia (código 07)? ¿Qué referencias rinden menos?	Power BI

2.2 Supuestos de cálculo (derivados del diagnóstico)

#	Supuesto	Razón
S1	**Horas programadas** = `Horas trabajadas` de la fila con producción (duración del turno registrada). El paro está incluido en ese tiempo.	Solo 45 de 5.160 filas tienen paro mayor que las horas trabajadas.
S2	**Tiempo productivo** = Horas programadas − Horas de paro, donde las horas de paro se suman de `fact_paro` (incluye las filas de subcódigo).	Es la lógica de la hoja `Tiempos` del Excel actual; usar `fact_paro` evita perder el 9,5 % del paro que viene en filas de subcódigo.
S3	**Meta por hora (pacas)** no se guarda en la base: las columnas de velocidad ideal están vacías en el 100 % de las filas. Se define una **velocidad de referencia por máquina y referencia** a partir del histórico (percentil 90 de pacas por hora productiva), almacenada en una tabla propia y editable.	Sin velocidad ideal no se puede calcular Rendimiento. Es la limitación más importante de la fuente.
S3b	Como la velocidad de referencia es el **percentil 90** y no un máximo teórico, el rendimiento (y por tanto el OEE) **puede superar 100 %** cuando una jornada o un mes supera su propia referencia (ocurre en pocos casos, p. ej. Vinilos_3 en 2023). En los tableros se muestra tal cual y se interpreta como "mejor que su referencia habitual".	Es una consecuencia de no tener la velocidad ideal del fabricante.
S4	**Calidad no se registra** (no hay producto no conforme). Versión 1: proxy = 1 − (horas de [11] Reproceso + [12] Materia prima defectuosa) / Horas programadas, declarado como aproximación. Se propone capturar unidades no conformes.	Sin ese dato, el componente Calidad del OEE no es medible directamente.
S5	**Paros programados**: los que la hoja `TABLA CODIGOS` clasifica con área de impacto "Paro programado" ([15] Cambio de insumos, [16] Alimentación y aseo, [17] Pausa activa), más [04] Mantenimiento preventivo y [18] Desinfección, que son programados por definición. El resto es no programado.	Permite separar pérdida controlable de pérdida programada, respetando la clasificación de la empresa.
S6	Las filas de subcódigo sin producción **no son jornadas**; solo aportan a paros, y sus horas son **adicionales** (no duplican las de la jornada).	Verificado con los datos; ver `docs/diagnostico/diagnostico_fuente.md`, sección 4.

#	Supuesto	Razón
S7	Las **11 jornadas con pacas imposibles** (más de 60 pacas por hora) conservan sus horas pero no sus pacas, y quedan fuera del cálculo de rendimiento (`valida_rendimiento = false`).	Evita que un error de digitación distorsione el OEE de Vinilos_1 en 2023.

Los umbrales de esta tabla son **iniciales**: se calibran con el histórico cuando el ETL esté cargado y se confirman con el coordinador de mantenimiento.

2.3 Catálogo de indicadores

Granularidad: la mínima a la que se puede calcular; todos se agregan por máquina, turno, referencia, mes y año.

3.1 Indicadores que reporta hoy el P-MTO-22

ID	Indicador	Fórmula	Unidad	Granularidad	Meta / umbral	Fuente	Usuario
I01	Productividad por máquina y mes	Pacas reales ÷ (velocidad de referencia × Tiempo productivo)	%	Máquina, mes	Meta ≥ 75 %; alerta < 65 % (el reporte actual muestra 76,3 % global)	`fact_produccion`	Dirección
I02	Comparativo anual de producción	Pacas reales del mes del año N frente a las del mismo mes del año N−1	Pacas y % de variación	Año, mes	Variación ≥ 0 %	`fact_produccion`	Dirección
I03	% de horas por código de paro	Horas del código ÷ Horas programadas	%	Máquina, mes, código	Cada código no planeado < 2 %; ajuste [05], aseo [16] y derrame [06] son los que hoy superan 4 %	`fact_paro`	Mantenimiento
I04	Detalle código 01 (falla electromecánica) por subcódigo	Horas del subcódigo ÷ Horas del código 01	%	Subcódigo	Informativo; Pareto	`fact_paro` , `dim_paro`	Mantenimiento
I05	Detalle código 03 (sistemas de potencia) por subcódigo	Igual que I04 para el código 03	%	Subcódigo	Informativo	`fact_paro`	Mantenimiento
I06	Detalle código 05 (ajuste operativo) por subcódigo y personal	Igual que I04 para el código 05, abierto por personal involucrado (operarios o mantenimiento)	%	Subcódigo, personal	Informativo	`fact_paro`	Mantenimiento

3.2 Indicadores nuevos que el Excel no calcula

ID	Indicador	Fórmula	Unidad	Granularidad	Meta / umbral	Fuente	Usuario
I07	Disponibilidad	Tiempo productivo ÷ Horas programadas	%	Jornada	Meta ≥ 90 %; alerta < 80 %	`fact_produccion` , `fact_paro`	Todos

ID	Indicador	Fórmula	Unidad	Granularidad	Meta / umbral	Fuente	Usuario
I08	Rendimiento	Pacas reales ÷ (velocidad de referencia × Tiempo productivo)	%	Jornada	Meta ≥ 95 %; alerta < 80 %	`fact_produccion`, tabla de velocidades	Dirección, producción
I09	Calidad (proxy v1)	1 − (horas [11] + [12]) ÷ Horas programadas	%	Jornada	Meta ≥ 99 %	`fact_paro`	Dirección
I10	**OEE**	Disponibilidad × Rendimiento × Calidad	%	Jornada, máquina, mes	Meta ≥ 65 % inicial, referencia mundial 85 %; alerta < 50 %	Derivado	Dirección
I11	Pareto de causas de paro	Horas por código ordenadas de mayor a menor y % acumulado	Horas y %	Código, subcódigo	80 % acumulado define las "pocas causas vitales"	`fact_paro`	Dirección, mantenimiento
I12	MTTR (tiempo medio de reparación)	Horas del código 01 ÷ Número de eventos del código 01	Horas	Máquina, mes	Tendencia decreciente	`fact_paro`	Mantenimiento
I13	MTBF (tiempo medio entre fallas)	Tiempo productivo ÷ Número de eventos del código 01	Horas	Máquina, mes	Tendencia creciente	`fact_paro`	Mantenimiento
I14	% de paro planeado frente a no planeado	Horas de paros planeados (S5) ÷ Horas de paro totales	%	Máquina, mes	No planeado < 50 % del paro total	`fact_paro`	Dirección, planeación
I15	Pacas por hora productiva	Pacas reales ÷ Tiempo productivo	Pacas/h	Jornada, referencia	Comparar contra la referencia	`fact_produccion`	Planeación
I16	Tiempo medio de cambio de referencia	Horas del código 07 ÷ Número de cambios	Horas	Máquina, mes	Tendencia decreciente	`fact_paro`	Planeación
I17	Variación mensual de OEE	OEE del mes − OEE del mes anterior	Puntos porcentuales	Máquina, mes	≥ 0	Derivado	Dirección

3.3 Indicadores operativos de Grafana (casi en tiempo real)

ID	Indicador	Fórmula	Unidad	Granularidad	Meta / umbral	Fuente	Usuario
I18	Estado actual por máquina	"Parada" si la última hora registrada tiene paro mayor que 30 min, "Produciendo" en caso contrario	Estado	Máquina, hora	—	Tabla de la simulación	Supervisores
I19	Pacas por hora (serie temporal)	Pacas registradas en la hora	Pacas/h	Máquina, hora	Referencia de la velocidad (S3)	`fact_produccion`	Supervisores

ID	Indicador	Fórmula	Unidad	Granularidad	Meta / umbral	Fuente	Usuario
I20	**Horas de paro en la última hora** (KPI de la alerta)	Suma de minutos de paro de la hora ÷ 60	Horas	Máquina, hora	**Alerta si > 0,5 h (30 min)** durante 2 horas seguidas: equivale a perder más de la mitad de la hora, el punto donde la disponibilidad horaria queda bajo 50 % y justifica llamar a mantenimiento	`fact_paro`	Supervisores, mantenimiento

2.4 Por qué estos indicadores nuevos

- **OEE (I07–I10):** resume en un número la pérdida de disponibilidad, velocidad y calidad. El Excel solo mide "eficiencia" frente a una meta digitada a mano y sin histórico.
- **Pareto (I11):** el gráfico actual muestra porcentajes por código, pero no el acumulado que permite priorizar.
- **MTTR y MTBF (I12, I13):** separan cuántas veces falla una máquina de cuánto tarda en repararse, dos decisiones de inversión distintas.
- **Planeado vs no planeado (I14):** evita corregir como "falla" lo que es una parada programada.
- **Tiempo de cambio de referencia (I16):** el código 07 acumula 620,8 h en la fuente; medirlo por cambio orienta la programación.
- **Indicadores horarios (I18–I20):** el reporte mensual llega demasiado tarde para actuar en el turno.

3. Diagnóstico de la fuente de datos

Fuente: `data/raw/SEGUIMIENTO_TEMPERAS_Y_VINILOS_Actividad.xlsm` (4,2 MB, 21 hojas) y procedimiento `P-MTO-22`. Todas las cifras salen de leer el archivo sin modificarlo.

3.1 Estructura del libro

Hoja	Estado	Contenido	Uso en el proyecto
`Base De Datos`	visible	8.208 registros × 58 columnas (encabezado en la fila 9)	**Fuente principal** de hechos
`Base de datos de Sub codigos`	oculta	1.260 filas × 19 columnas	Detalle de subcódigos, área y personal involucrado
`TABLA CODIGOS`	oculta	Área de impacto, códigos de paro y jerarquía de subcódigos	**Fuente de la dimensión de paros**
`Registro`, `Tiempos`	visible	Formulario de captura (botones con macros) y cálculo de tiempos	Se documenta, no se carga
`TD_*`, `prod*`, `ajusteOperativo`, `fallaMecanica`, `novPotencia`	visible	Tablas dinámicas y gráficos del informe actual	Referencia de los indicadores actuales
`Calculadora de tiempos`, `Hoja1`, `Hoja4`, `Tablas Desplegables`	oculta/visible	Apoyo	No se cargan

Cada fila de `Base De Datos` es una **jornada de una máquina con un operario, una referencia y un turno**. Cubre del **2022-01-01 al 2025-03-28**:

Año	Registros
2022	1.654
2023	2.891
2024	3.129
2025 (parcial)	534

Máquinas: Vinilos_1 (1.877), Vinilos_2 (1.255), Vinilos_3 (2.491), Vinilos_4 (2.585). Operarios distintos: 34. Referencias distintas: 52.

3.2 Qué está bien

- Las 8.208 fechas son válidas y la columna `Año` coincide con el año de `Fecha` en todas las filas.
- `Tiempo de Paro` **es igual a la suma de las 18 columnas "Código N en horas" en el 100 % de las filas.** Sirve como control de cuadre del ETL.
- No hay valores negativos en pacas, horas trabajadas ni tiempo de paro.

3.3 Problemas de calidad de datos

#	Problema	Evidencia	Tratamiento propuesto en el ETL
1	**Paros en formato ancho**: 18 pares "Código N" / "Código N en horas" por fila	58 columnas	Despivotar a una fila por (jornada, código de paro) con horas > 0

#	Problema	Evidencia	Tratamiento propuesto en el ETL
2	**Turno inconsistente**	8 valores: `6am-2pm (Turno 1)` 1.352, `2pm-10pm (Turno 2)` 1.182, `10pm-6am (Turno 3)` 1.012, `6am-4:30pm` 359, `No aplica` 336, `6am-6pm` 35, `6pm-6am` 20, nulo 3.912	Catálogo único de turnos; nulo o `No aplica` pasa a "Sin turno" y se reporta el conteo
3	**Dos catálogos de "Tipo de paro" mezclados**	Esquema antiguo (`17. PARO DE MAQUINA` 952, `9.FALTA DE PROGRAMACIÓN` 251, …) y esquema nuevo (`[19] No aplica` 2.282, `[18] Paro de maquina por ventas` 605, …); 3.782 nulos	Tabla de equivalencias antiguo → nuevo, documentada
4	**Filas de subcódigo sin producción**	3.048 filas (37 %) sin pacas ni horas trabajadas; 3.047 tienen un subcódigo. Suman 799,2 h de paro (9,5 % de 8.449,7 h). 2.120 tienen una fila "padre" con producción en la misma fecha, máquina y turno	No cuentan como jornadas: alimentan solo la tabla de hechos de paros
5	**Operario y referencia nulos**	Operario nulo 3.721 y `No aplica` 537; referencia nula 3.874	Miembro "Desconocido" en la dimensión; se reporta el conteo
6	**Duplicados**	42 duplicados exactos; 5.377 filas comparten (fecha, máquina, operario, referencia, turno)	Eliminar los exactos; los demás son legítimos (varias referencias o subcódigos en una jornada) y se conservan
7	**Valores atípicos**	Pacas: máximo 9.417 con media 73,45	Marcar con bandera de calidad y revisar caso por caso
8	**Ceros**	427 filas con pacas = 0 y 401 con horas trabajadas = 0	Mantener, con bandera para no inflar promedios
9	**Código 18 sin documentar**	El PDF lista 17 códigos; el Excel y los gráficos usan 18 (`Desinfección`) y el tipo `[19] No aplica`	Se agrega a la dimensión de paros
10	**Datos personales**	34 nombres de operarios en texto claro	Seudonimizar en el modelo (ver sección de seguridad)
11	**Archivo con macros**	`.xlsm`; las hojas `Registro` y `Tiempos` dependen de VBA	El ETL lee solo valores (`data_only`) y no ejecuta macros

3.4 Punto que estaba abierto: las filas de subcódigo (resuelto)

Las filas de subcódigo traen sus propias horas de paro. Se verificó con los datos que **son horas adicionales y no doble conteo**:

- Son casi todas del código 05 (723,3 h), más el 01 (60,0 h) y el 03 (15,8 h).
- Solo la mitad se puede ligar a una jornada con seguridad (1.470 de 3.048 tienen una jornada única con la misma fecha, máquina, operario y referencia), y en esas el código 05 aparece en la jornada solo 280 veces frente a 1.229 en la fila de subcódigo.
- La hoja oculta `Base de datos de Sub codigos` (1.252 filas) está contenida por completo en `Base De Datos`, así que no aporta datos nuevos.

Regla aplicada: las filas de subcódigo no son jornadas y se cargan como **eventos de paro propios** (sus horas se suman al total). Por eso la disponibilidad se calcula con las horas de `fact_paro`, no con la columna `horas_paro` de `fact_produccion`.

3.5 Hallazgos adicionales al cargar los datos

Hallazgo	Detalle
Pacas imposibles	11 jornadas de Vinilos_1 en julio de 2023 con entre 3.552 y 9.417 pacas en 8 h (unas 500 por hora, cuando lo normal son 7). Suman 52.493 pacas, el 14 % del total. Parecen unidades digitadas como pacas.

Hallazgo	Detalle
Subcódigos con dos catálogos	En el código 05 conviven la numeración antigua `4.x` y la actual `5.x`, y no coinciden (el antiguo 4.4 Transfer es hoy el 5.5).
Meta no guardada	Las columnas de velocidad ideal (unidades por minuto, unidades por display, displays por paca) están vacías en el 100 % de las filas.
Código 1.1 con dos nombres	El catálogo lo llama "Falla mecánica"; los datos y los gráficos del P-MTO-22 usan "Sistema alimentador de envases".

3.6 Limitaciones del esquema actual de reporte

3.7 Limitaciones del esquema actual de reporte

1. **No calcula OEE** ni sus componentes (disponibilidad, rendimiento, calidad).
2. **Cobertura parcial en 2025**: el comparativo 2024 vs 2025 llega solo hasta marzo/abril.
3. **Jerarquía de paros oculta**: la relación código → subcódigo vive en una hoja oculta y se analiza solo para los códigos 01, 03 y 05.
4. **Captura manual**: papel → transcripción → Excel con macros; los errores de digitación (problemas 5, 7 y 8) no se validan al ingresar.
5. **Sin tiempo casi real**: el análisis es mensual y los supervisores no reciben alertas.
6. **Modelo ancho y sin llaves**: no hay identificador de registro; cualquier cruce depende de combinaciones de texto.
7. **Sin trazabilidad de calidad**: no se registra producto no conforme, lo que impide medir el componente "Calidad" del OEE.

4. Modelo dimensional

4.1 Decisión: esquema en estrella

Se usa un **esquema en estrella** con tablas de hechos y dimensiones desnormalizadas, en PostgreSQL.

Alternativa	Por qué no
Una sola tabla ancha (como el Excel)	Es el problema actual: 58 columnas, 18 pares código/horas y sin llaves. No permite jerarquías ni cruces limpios.
Copo de nieve (snowflake)	Normaliza las dimensiones y agrega uniones. Con 4 máquinas, 52 referencias y 18 códigos no ahorra espacio y hace más lentas las consultas de Grafana y más confuso el modelo semántico de Power BI.
Estrella	Menos uniones, consultas simples, jerarquías de un solo nivel por dimensión (ideal para el drill-down de Power BI) y buen rendimiento en agregaciones.

4.2 Tablas de hechos y su granularidad

Tabla	**Granularidad (una fila es…)**	Medidas	Origen
`fact_produccion`	Una **jornada**: una máquina, un día, un turno, un operario y una referencia. Son las filas de `Base De Datos` con producción (5.138 tras eliminar 22 duplicados).	`pacas_producidas`, `pacas_origen`, `horas_programadas`, `horas_paro`, `horas_productivas` (derivada), `valida_rendimiento`	`Base De Datos`
`fact_paro`	Un **evento de paro**: una jornada y un código de paro (y subcódigo, si lo tiene) con horas mayores que cero. Resulta de despivotar las 18 columnas "Código N en horas".	`horas_paro`, `minutos_paro`, `eventos` (siempre 1, para contar fallas)	`Base De Datos` y `Base de datos de Sub codigos`
`fact_registro_horario`	**Una hora de una máquina** en el tiempo casi real. Es la tabla que alimenta la simulación y Grafana.	`pacas_hora`, `minutos_paro`	Script de simulación (sin histórico)

`horas_paro` de `fact_produccion` es solo el paro registrado en la propia fila de la jornada. El paro completo, incluidas las filas de subcódigo, está en `fact_paro`, y **es el que debe usarse para disponibilidad y OEE**. Las medidas de rendimiento deben filtrar `valida_rendimiento = true`.

Reglas de granularidad:

- Las **filas de subcódigo sin producción no son jornadas**: solo generan filas en `fact_paro`.
- Las medidas son **aditivas** (suman por cualquier dimensión). Los porcentajes y el OEE **no se guardan**: se calculan en SQL y en DAX para que los totales sean correctos.
- La llave natural (fecha, máquina, operario, referencia, turno) se repite en 5.377 filas, así que cada hecho lleva una **llave sustituta** y el número de fila de origen para poder auditar.

4.3 Dimensiones

Dimensión	Llave	Atributos	Jerarquía	Origen
`dim_fecha` (construida por nosotros)	`fecha_key` (aaaammdd)	fecha, año, trimestre, mes, nombre del mes, semana ISO, día del mes, día de la semana, es fin de semana, año-mes	Año → Trimestre → Mes → Día	Calendario generado (2022-01-01 en adelante), no viene del Excel
`dim_hora` (construida)	`hora_key` (0–23)	hora, franja (madrugada, mañana, tarde, noche)	Franja → Hora	Generada

Dimensión	Llave	Atributos	Jerarquía	Origen
`dim_maquina`	`maquina_key`	nombre (Vinilos_1 a Vinilos_4), línea de producto	Línea → Máquina	`Maquina`
`dim_turno` (construida)	`turno_key`	nombre limpio, hora de inicio, hora de fin, duración en horas	Tipo de turno → Turno	`Turno`, con catálogo de equivalencias (8 valores crudos → 7 turnos)
`dim_referencia`	`referencia_key`	nombre estándar (erratas y formato corregidos), producto, contenido en cc, número de colores	Producto → Referencia	`Referencia`, separando por ejemplo "Parchesitos 22cc (6 col)"
`dim_operario`	`operario_key`	código seudónimo (OP-001), activo	—	`Operario` (ver privacidad)
`dim_paro`	`paro_key`	área de impacto, código y nombre, es programado, subsistema (código y nombre), detalle (código y nombre)	Área de impacto → Código → Subsistema → Detalle	`TABLA CODIGOS` y equivalencias
`dim_area_involucrada`	`area_key`	Operarios, Personal de mantenimiento, No especificado	—	`Área involucrada en subcódigo`
`dim_meta_velocidad`	`meta_key`	máquina, referencia, pacas por hora de referencia, vigente desde, vigente hasta, es vigente	—	Calculada del histórico (supuesto S3)

Todas las dimensiones tienen un miembro **"Desconocido" (llave −1)** para los nulos de la fuente (3.721 operarios, 3.874 referencias y 3.912 turnos), de modo que ningún hecho se pierde en una unión.

Cómo se modela la jerarquía de los paros

Los paros se guardan en **una sola dimensión desnormalizada, `dim_paro`, con una fila por hoja de la jerarquía** y cuatro niveles como columnas:

```
Área de impacto → Código de paro → Subsistema → Detalle
```

Ejemplo: Mantenimiento → [01] Falla electromecánica → 1.2 Sistema de dosificación → 1.2.B Ajuste de sensor.

Por qué así:

- **La jerarquía es irregular**: la fuente solo captura subcódigos para los códigos 01, 03 y 05, y solo el 01 tiene un tercer nivel. Los códigos sin subcódigo reciben una fila con "Sin subcódigo" en los niveles inferiores, así la profundidad es fija.
- **Cada hecho apunta al nivel más fino disponible**, y los totales por código, subsistema o área salen sumando hacia arriba, lo que habilita el **drill-down** y el **Pareto** en Power BI sin lógica extra.
- **Se descarta la tabla padre-hijo** (con `PATH` en DAX) porque la profundidad es conocida y fija; evita fórmulas más complejas para un beneficio nulo.
- **El área de impacto** (Mantenimiento, Producción, Calidad, Almacén, Paro programado) viene de la propia empresa y responde "¿quién puede actuar sobre este paro?".
- `es_programado` (supuesto S5) vive aquí, así que separar paro programado de no programado es un simple filtro.

4.4 Matriz de bus

Proceso de negocio	fecha	hora	máquina	turno	referencia	operario	paro	área involucrada	meta velocidad
Producción por jornada (`fact_produccion`)	✓		✓	✓	✓	✓			✓
Paros de producción (`fact_paro`)	✓		✓	✓	✓	✓	✓	✓	
Registro horario casi en tiempo real (`fact_registro_horario`)	✓	✓	✓	✓	✓		✓		✓

Las dimensiones compartidas (**fecha, máquina, turno, referencia**) están **conformadas**: son las mismas tablas en los tres procesos, así que se pueden comparar y cruzar (por ejemplo, horas de paro frente a pacas por máquina y mes).

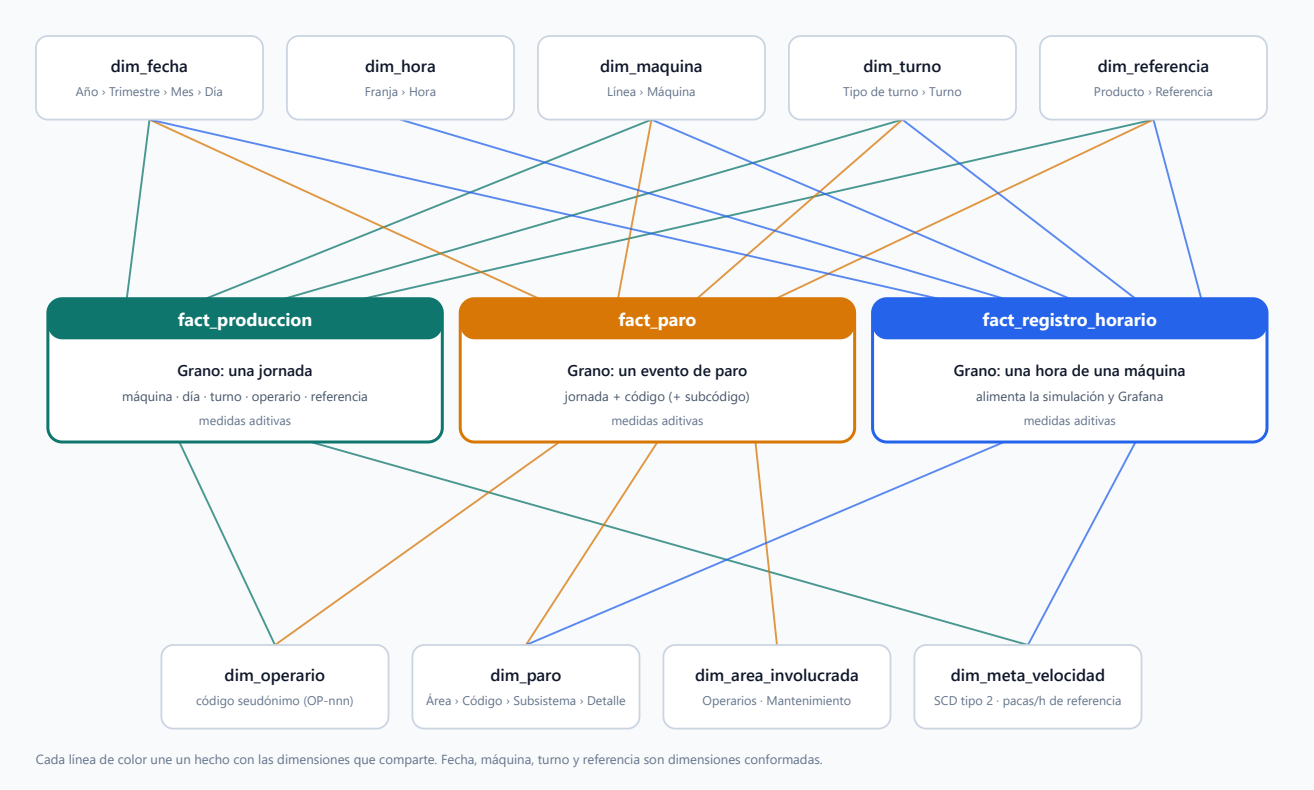
4.5 Dimensión de cambio lento (bonificación)

Candidata: `dim_meta_velocidad`, tipo 2.

- La velocidad de referencia de una máquina y referencia **cambia con el tiempo** (recalibraciones, mejoras) y la fuente no guarda histórico.
- Si se sobrescribiera (tipo 1), el rendimiento de 2022 se evaluaría con la meta de hoy y el histórico quedaría distorsionado.
- Con **tipo 2** cada cambio crea una fila nueva con `vigente_desde`, `vigente_hasta` y `es_vigente`; cada jornada se compara con la meta que estaba vigente ese día.

Las demás dimensiones usan **tipo 1** (se sobrescribe): las correcciones de nombre no necesitan historia.

4.6 Diagrama



Cada línea de color une un hecho con las dimensiones que comparte. Fecha, máquina, turno y referencia son dimensiones conformadas.

El diccionario de datos completo (columnas, tipos, llaves, reglas de transformación y origen de cada campo) está en diccionario_datos.md, generado desde la propia base para que no se desfase del DDL. A estas tablas se suman `seguridad.operario_pii` (nombres reales, acceso restringido) y `calidad.incidencias` (bitácora de correcciones del ETL).

5. Diccionario de datos

Generado por `python etl/diccionario.py`. Los tipos y llaves se leen de la base; el origen y las reglas estan en el propio script. Modelo y justificacion: modelo_dimensional.md. Reglas de limpieza con conteos: validacion_etl.md.

5.1 `dw.dim_fecha`

Calendario. Una fila por dia.

Origen: Generada por SQL (`sql/init/02_seed.sql`), 2022-01-01 a 2030-12-31.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`fecha_key`	integer	no	PK	aaaammdd, p. ej. 20250328.
`fecha`	date	no		Dia calendario.
`anio`	smallint	no		Anio de la fecha.
`trimestre`	smallint	no		1 a 4.
`mes`	smallint	no		1 a 12.
`nombre_mes`	text	no		En espanol, minuscula.
`semana_iso`	smallint	no		Semana ISO 8601.
`dia`	smallint	no		Dia del mes.
`dia_semana`	smallint	no		1 = lunes a 7 = domingo.
`nombre_dia`	text	no		En espanol, minuscula.
`es_fin_semana`	boolean	no		Sabado o domingo.
`anio_mes`	char(7)	no		Formato aaaa-mm, para ordenar y filtrar.

5.2 `dw.dim_hora`

Horas del dia, para el monitoreo hora a hora.

Origen: Generada por SQL.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`hora_key`	smallint	no	PK	0 a 23.
`franja`	text	no		madrugada (0-5), manana (6-11), tarde (12-17), noche (18-23).

5.3 `dw.dim_maquina`

Maquinas de envasado.

Origen: `Base De Datos.Maquina`.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`maquina_key`	integer	no	PK	Llave sustituta; -1 = Desconocida.
`nombre`	text	no		Valores distintos de `Maquina`, sin espacios sobrantes.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`linea_producto`	text	no		Texto antes del guion bajo del nombre (Vinilos_1 -> Vinilos).

5.4 `dw.dim_turno`

Catalogo limpio de turnos.

Origen: Construida a mano (`sql/init/02_seed.sql`); el ETL mapea el texto crudo con `limpiar.clave_turno` .

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`turno_key`	smallint	no	PK	-1 = Sin turno (nulo o 'No aplica' en la fuente; 47 % de las jornadas).
`nombre`	text	no		Nombre unico del turno.
`tipo_turno`	text	no		Turno de 8 h, jornada extendida, turno de 12 h o Desconocido.
`hora_inicio`	time without time zone	si		Inicio del turno.
`hora_fin`	time without time zone	si		Fin del turno.
`duracion_horas`	numeric(4,1)	si		Duracion en horas.

5.5 `dw.dim_referencia`

Referencias (productos) envasadas.

Origen: `Base De Datos` . `Referencia` .

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`referencia_key`	integer	no	PK	Llave sustituta ordenada por nombre; -1 = Desconocida (nulo o 'No aplica').
`nombre_estandar`	text	no		Nombre con erratas corregidas (Alocdor, Stilo Kids) y formato unico `<producto> <cc>cc (<n> col)` .
`producto`	text	no		Nombre sin contenido ni colores.
`contenido_cc`	smallint	si		Numero antes de 'cc'; nulo si no aplica.
`num_colores`	smallint	si		Numero dentro de '(n col)'; nulo si no aplica.

5.6 `dw.dim_operario`

Operarias y operarios, seudonimizados.

Origen: `Base De Datos` . `Operario` .

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`operario_key`	integer	no	PK	Llave sustituta; -1 = Desconocido ('No', 'No aplica' o nulo).
`codigo_seudonimo`	text	no		OP-nnn asignado por orden alfabetico del nombre. El nombre real no esta en este esquema.
`activo`	boolean	no		Siempre verdadero (la fuente no informa retiros).

5.7 `dw.dim_paro`

Jerarquia de paros: area de impacto, codigo, subsistema y detalle. Una fila por hoja.

Origen: Hoja `TABLA CODIGOS` del Excel y el codigo 18 del formulario.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`paro_key`	integer	no	PK	Llave sustituta; -1 = Sin paro.
`area_impacto`	text	no		Columna 'AREA DE IMPACTO' de `TABLA CODIGOS`; el codigo 18 se asigna a Paro programado.
`codigo_paro`	smallint	no		Numero entre corchetes: [05] -> 5.
`nombre_codigo`	text	no		Texto del codigo sin el prefijo.
`es_programado`	boolean	no		Verdadero si el area es Paro programado o el codigo es 4 o 18 (supuesto S5).
`subsistema_codigo`	text	no		p. ej. 1.2; 'Sin subcodigo' si el codigo no trae subcodigo.
`subsistema_nombre`	text	no		Del catalogo; 1.1 se nombra como en los datos y graficos del P-MTO-22.
`detalle_codigo`	text	no		p. ej. 1.2.B (solo codigo 01); 'Sin detalle' si hay subsistema sin detalle.
`detalle_nombre`	text	no		Del catalogo.

5.8 `dw.dim_area_involucrada`

Quien participa en el paro de ajuste operativo.

Origen: Generada a mano (`sql/init/02_seed.sql`).

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`area_key`	smallint	no	PK	-1 = No especificado.
`nombre`	text	no		Operarios o Personal de mantenimiento.

5.9 `dw.dim_meta_velocidad`

Velocidad de referencia (pacas por hora) por maquina y referencia. SCD tipo 2.

Origen: Calculada por `transformar.construir_meta` a partir del historico (la fuente no guarda la meta).

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`meta_key`	integer	no	PK	Llave sustituta; -1 = sin meta.
`maquina_key`	integer	no	FK -> dw.dim_maquina	Maquina de la meta.
`referencia_key`	integer	no	FK -> dw.dim_referencia	Referencia de la meta; -1 = general de la maquina (respaldo).
`pacas_por_hora`	numeric(8,2)	no		Percentil 90 de pacas por hora productiva de ese anio, con minimo de 10 jornadas validas.
`vigente_desde`	date	no		1 de enero del anio de la version.
`vigente_hasta`	date	si		31 de diciembre; nulo en la version vigente.
`es_vigente`	boolean	no		Verdadero en la version mas reciente de cada maquina y referencia.

5.10 `dw.fact_produccion`

Una fila por jornada: maquina, dia, turno, operario y referencia.

Origen: `Base De Datos`, filas con pacas u horas trabajadas, despues de eliminar duplicados exactos.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`produccion_id`	bigint	no	PK	Identidad generada por la base.
`fecha_key`	integer	no	FK -> dw.dim_fecha	`Fecha` -> aaaammdd.
`maquina_key`	integer	no	FK -> dw.dim_maquina	`Maquina` -> dim_maquina.
`turno_key`	smallint	no	FK -> dw.dim_turno	`Turno` -> `limpiar.clave_turno`.
`referencia_key`	integer	no	FK -> dw.dim_referencia	`Referencia` estandarizada; -1 si es nula.
`operario_key`	integer	no	FK -> dw.dim_operario	`Operario` limpio; -1 si es nulo.
`meta_key`	integer	no	FK -> dw.dim_meta_velocidad	Meta de la maquina, referencia y anio; si no existe, la general de la maquina.
`pacas_producidas`	numeric(10,2)	si		`Pacas producidas`; nulo si supera 60 pacas por hora (regla `pacas_atipicas`).
`pacas_origen`	numeric(10,2)	si		`Pacas producidas` tal como viene en el Excel.
`horas_programadas`	numeric(5,2)	no		`Horas trabajadas`; nulo -> 0.
`horas_paro`	numeric(10,6)	no		`Tiempo de Paro` de la propia fila. No incluye las filas de subcodigo (estan en fact_paro).
`horas_productivas`	numeric(10,6) (calculada)	si		Calculada: max(horas_programadas - horas_paro, 0).
`valida_rendimiento`	boolean	no		Verdadero si pacas_producidas no es nulo y las horas productivas son mayores que 0.
`bandera_calidad`	text	si		Reglas que aplican: pacas_atipicas, sin_pacas, sin_horas, cero_pacas, cero_horas, paro_mayor_horas.
`fila_origen`	integer	no		Numero de fila en la hoja del Excel, para auditar.

5.11 `dw.fact_paro`

Una fila por evento de paro: jornada o fila de subcodigo, y codigo de paro (con subcodigo si lo tiene).

Origen: `Base De Datos`, columnas `Codigo N en horas` (N = 1 a 18) despivotadas; se conserva el evento si las horas son mayores que 0.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`paro_id`	bigint	no	PK	Identidad generada por la base.
`fecha_key`	integer	no	FK -> dw.dim_fecha	`Fecha` de la fila.
`maquina_key`	integer	no	FK -> dw.dim_maquina	`Maquina` de la fila.
`turno_key`	smallint	no	FK -> dw.dim_turno	`Turno` de la fila.
`referencia_key`	integer	no	FK -> dw.dim_referencia	`Referencia` de la fila.
`operario_key`	integer	no	FK -> dw.dim_operario	`Operario` de la fila.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`paro_key`	integer	no	FK -> dw.dim_paro	Codigo N + subcodigo normalizado (`limpiar.normalizar_subcodigo`) -> hoja de dim_paro.
`area_key`	smallint	no	FK -> dw.dim_area_involucrada	`Area involucrada en subcodigo 5` , solo para el codigo 5; los demas codigos usan -1.
`horas_paro`	numeric(10,6)	no		`Codigo N en horas` , sin redondear.
`minutos_paro`	numeric(12,4) (calculada)	si		Calculada: horas_paro * 60.
`eventos`	smallint	no		Siempre 1; sirve para contar fallas (MTBF, MTTR).
`hoja_origen`	text	no		Hoja del Excel de la que sale el evento.
`fila_origen`	integer	no		Numero de fila en esa hoja.

5.12 `dw.fact_registro_horario`

Una fila por maquina y hora. Lo alimenta la simulacion para el monitoreo en Grafana.

Origen: Script de simulacion (fase de Grafana); sin historico.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`registro_id`	bigint	no	PK	Identidad generada por la base.
`fecha_hora`	timestamp	no		Inicio de la hora simulada.
`fecha_key`	integer	no	FK -> dw.dim_fecha	Dia de `fecha_hora` , en aaaammdd.
`hora_key`	smallint	no	FK -> dw.dim_hora	Hora (0 a 23) de `fecha_hora` .
`maquina_key`	integer	no	FK -> dw.dim_maquina	Maquina simulada.
`turno_key`	smallint	no	FK -> dw.dim_turno	Turno al que pertenece la hora.
`referencia_key`	integer	no	FK -> dw.dim_referencia	Referencia que la simulacion asigna a la maquina.
`paro_key`	integer	no	FK -> dw.dim_paro	Causa del paro simulado; -1 si la hora no tuvo paro.
`meta_key`	integer	no	FK -> dw.dim_meta_velocidad	Meta vigente de la maquina y referencia en esa fecha.
`pacas_hora`	numeric(8,2)	no		Pacas producidas en la hora.
`minutos_paro`	numeric(5,2)	no		Minutos de paro dentro de la hora (0 a 60).

5.13 `seguridad.operario_pii`

Nombre real de cada operario. Acceso restringido; los tableros no lo leen.

Origen: `Base De Datos` . `Operario` .

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`operario_key`	integer	no	FK -> dw.dim_operario	Llave de dim_operario.
`nombre_original`	text	no		Nombre sin espacios sobrantes.

5.14 `calidad.incidencias`

Bitacora de correcciones del ETL, una fila por hallazgo.

Origen: Generada por `transformar.py`.

Columna	Tipo	Nulo	Llave	Origen y regla de transformacion
`incidencia_id`	integer	no	PK	Identidad generada.
`hoja_origen`	text	no		Hoja del Excel.
`fila_origen`	integer	no		Fila en esa hoja.
`regla`	text	no		duplicado_exacto o pacas_atipicas.
`accion`	text	no		Fila eliminada o valor anulado.
`detalle`	text	si		Valores afectados.

6. ETL: del Excel al modelo estrella

El ETL toma el Excel de seguimiento, lo limpia y lo carga en PostgreSQL. Despues comprueba que los totales cuadren con el Excel.

6.1 Como ejecutarlo (desde la raiz del repositorio)

```
docker compose up -d --wait                       # 1. levantar PostgreSQL
python -m venv .venv                              # 2. crear el entorno de Python (solo la primera vez)
.venv\Scripts\python -m pip install -r etl\requirements.txt
.venv\Scripts\python etl\main.py                  # 3. correr el ETL
```

Necesita el archivo `.env` (copiar `.env.example` y poner contrasenas). Se puede ejecutar las veces que se quiera: cada corrida borra lo que cargo la anterior y lo vuelve a cargar, dentro de una transaccion (si algo falla, la base queda como estaba).

Al terminar escribe el informe `docs/validacion_etl.md` y muestra `TODO CUADRA` o `HAY DIFERENCIAS SIN EXPLICAR`.

6.2 Que hace cada archivo

Archivo	Etapa	Que hace
`main.py`	Orquesta	Llama a las cuatro etapas en orden e imprime el resumen.
`config.py`	—	Rutas, parametros de negocio (umbrales) y conexion a la base.
`extraer.py`	1. Extraer	Lee la hoja `Base De Datos` y la tabla de codigos. No cambia ningun dato.
`limpiar.py`	2. Transformar	Reglas de limpieza: turnos, operarios, referencias, subcodigos. Son funciones pequenas y con pruebas.
`transformar.py`	2. Transformar	Elimina duplicados, arma dimensiones y hechos, despivota los 18 codigos de paro y calcula la velocidad de referencia.
`cargar.py`	3. Cargar	Inserta las tablas en PostgreSQL con `COPY`.
`validar.py`	4. Validar	Cuadra los totales contra el Excel y escribe el informe.
`diccionario.py`	Documentacion	Genera `docs/diccionario_datos.md` desde la base. Se corre aparte.
`tests/test_limpiar.py`	Pruebas	Verifica las reglas de limpieza: `.venv\Scripts\python -m pytest etl\tests`.

6.3 Por que Python

- Hay que **despivotar** 18 pares de columnas "codigo / horas" y **normalizar texto sucio** (subcodigos con dos formatos y erratas, referencias con variantes). Eso es largo y fragil en SQL o Power Query; en pandas son unas pocas lineas con pruebas.
- Es **reproducible** (un comando, sin clics) y queda en Git, a diferencia de un flujo de Power Query dentro de un `.pbix`.
- Se separa del consumo: la misma base sirve a Power BI y a Grafana.

6.4 Reglas de limpieza (resumen)

El detalle con conteos antes y despues esta en `docs/validacion_etl.md`.

Regla	Que se hace	Por que
Duplicados exactos	Se eliminan 42 filas iguales en las 58 columnas y se anotan en `calidad.incidencias`.	Son copias de un mismo registro.
Filas de subcodigo	No se cuentan como jornadas: solo generan eventos de paro.	No tienen produccion; contarlas bajaria artificialmente los promedios.
Turno	8 formas de escribirlo pasan a 6 turnos; nulo o `No aplica` pasa a `Sin turno`.	Un catalogo unico permite comparar.
Operario	`No` y `No aplica` pasan a nulo; cada nombre recibe un codigo `OP-nnn`; el nombre va a un esquema aparte.	Proteccion de datos personales.
Referencia	Se corrigen erratas (`Alocdor`, `Stilo Kids`) y se unifica el formato.	Evita contar la misma referencia como dos.
Subcodigo	Se normalizan los dos formatos; el catalogo antiguo `4.x` del codigo 05 se convierte al actual `5.x` por nombre.	Permite el drill-down por subsistema.
Pacas atipicas	Si una jornada supera 60 pacas por hora, la cifra se anula y se conserva en `pacas_origen`.	Son 11 jornadas de Vinilos_1 (julio de 2023) que parecen unidades digitadas como pacas; inflaban el total en 14 %.
Velocidad de referencia	Percentil 90 de pacas por hora productiva, por maquina, referencia y anio (minimo 10 jornadas).	La fuente no guarda la meta; hace falta para calcular el rendimiento del OEE.
Hoja oculta de subcodigos	No se carga.	Sus 1.252 filas ya estan todas en `Base De Datos`.

6.5 Parametros que se pueden cambiar

Estan al inicio de `config.py`: el umbral de pacas atipicas (60 por hora), el percentil de la velocidad de referencia (0,90), el minimo de jornadas (10) y los codigos de paro programados.

7. Validacion del ETL

Informe generado automaticamente por `python etl/main.py` (`etl/validar.py`). No editar a mano.

7.1 Reglas de limpieza aplicadas (antes y despues)

Regla	Antes	Despues	Detalle
Eliminar duplicados exactos	8,208	8,166	42 filas copia de otra fila
Separar jornadas y filas de subcodigo	8,166	5,138	3028 filas de subcodigo no son jornadas: solo aportan a paros
Unificar turnos	8	7	valores crudos (incluye nulo) -> turnos distintos; 2605 jornadas quedan 'Sin turno'; 0 valores no reconocidos
Estandarizar referencias	52	48	nombres crudos -> referencias unicas (erratas y formato corregidos); 4181 filas sin referencia (Desconocida)
Seudonimizar operarios	34	32	nombres crudos -> operarios con codigo OP-nnn ('No' y 'No aplica' son nulos); 4236 filas sin operario (Desconocido)
Anular pacas atipicas	5,135	5,124	11 jornadas con mas de 60 pacas/h (52,493 pacas); se conserva el valor en pacas_origen
Marcar jornadas con datos dudosos	5,138	439	se cargan con bandera_calidad: pacas_atipicas=11, sin_pacas=3, sin_horas=1, cero_pacas=421, cero_horas=396, paro_mayor_horas=45
Jornadas validas para calcular rendimiento	5,138	4,715	con pacas validas y horas productivas > 0
Calcular velocidad de referencia (SCD tipo 2)	5,138	68	68 versiones de meta; 4879 jornadas usan la meta de su referencia, 259 usan la general de la maquina
Despivotar 18 pares codigo/horas	146,988	16,482	celdas de codigo -> eventos de paro con horas > 0
Normalizar subcodigos	67	59	textos crudos -> hojas de jerarquia usadas; eventos: 2644 ok, 940 del catalogo antiguo (4.x -> 5.x), 12898 sin subcodigo, 0 no reconocidos, 0 sin hoja en el catalogo
Hoja oculta 'Base de datos de Sub codigos'	1,252	0	no se carga: sus 1.252 filas ya estan todas en 'Base De Datos' (verificado por fecha, maquina, operario y referencia)

7.2 Cuadre de totales contra la fuente

Regla: **fuente − ajuste = cargado**. El ajuste son las filas duplicadas eliminadas y las pacas atipicas anuladas (ver seccion 1).

Medida	Fuente (Excel)	Ajuste	Cargado en la base	Diferencia	Estado
Pacas producidas	378,778.00	53,512.00	325,266.00	0.0000	OK
Horas trabajadas (programadas)	38,063.35	129.00	37,934.35	0.0000	OK
Tiempo de paro (horas)	8,449.65	18.12	8,431.54	-0.0004	OK
Horas del codigo 01	323.90	1.32	322.58	-0.0000	OK
Horas del codigo 02	32.58	0.00	32.58	-0.0000	OK
Horas del codigo 03	87.13	0.58	86.55	-0.0000	OK
Horas del codigo 04	8.50	0.00	8.50	0.0000	OK
Horas del codigo 05	1,819.33	5.63	1,813.69	-0.0000	OK

Medida	Fuente (Excel)	Ajuste	Cargado en la base	Diferencia	Estado
Horas del codigo 06	1,546.90	1.08	1,545.82	0.0000	OK
Horas del codigo 07	620.81	0.00	620.81	-0.0000	OK
Horas del codigo 08	68.13	0.00	68.13	-0.0000	OK
Horas del codigo 09	182.13	0.33	181.80	-0.0000	OK
Horas del codigo 10	356.38	0.00	356.38	0.0000	OK
Horas del codigo 11	9.05	0.00	9.05	0.0000	OK
Horas del codigo 12	227.02	0.35	226.67	0.0000	OK
Horas del codigo 13	19.13	0.00	19.13	0.0000	OK
Horas del codigo 14	253.47	0.00	253.47	-0.0000	OK
Horas del codigo 15	165.83	1.20	164.63	-0.0000	OK
Horas del codigo 16	2,002.55	2.33	2,000.22	-0.0004	OK
Horas del codigo 17	718.43	5.28	713.15	-0.0000	OK
Horas del codigo 18	8.37	0.00	8.37	0.0000	OK

7.3 Cuadre por maquina y anio

- Produccion: 16 combinaciones de maquina y anio comparadas (jornadas, pacas y horas). Diferencia maxima: **0.0000** → OK.
- Paros: 16 combinaciones comparadas (eventos y horas). Diferencia maxima: **0.0001** → OK.
- Filas cargadas: 5,138 jornadas y 16,482 eventos de paro → OK.
- Incidencias de calidad registradas en `calidad.incidencias`: 53.

7.4 Conclusion

El proceso cuadra con la fuente. Toda diferencia entre el Excel y la base esta explicada por los duplicados eliminados y las pacas atipicas anuladas, y queda registrada fila por fila en `calidad.incidencias`.

8. Base de datos: DDL, restricciones, índices y consultas

Motor: **PostgreSQL 16**, administrado desde **DBeaver** (conexión al contenedor, puerto `POSTGRES_PORT`). El DDL completo está en `sql/init/01_ddl.sql` y se ejecuta solo al crear el contenedor, junto con los datos fijos (`02_seed.sql`), las vistas (`03_vistas.sql`) y el usuario de solo lectura (`04_roles.sh`).

8.1 Esquemas

Esquema	Contenido
`dw`	Modelo estrella: 9 dimensiones y 3 tablas de hechos. Lo que consumen Power BI y Grafana
`seguridad`	Nombres reales de los operarios; acceso restringido
`calidad`	Bitácora de correcciones del ETL (`incidencias`)

8.2 Restricciones y por qué

Restricción	Dónde	Qué protege
Llave primaria	Todas las tablas	Una fila, una identidad; permite que las uniones sean exactas
Llaves foráneas	Cada llave de dimensión en los hechos	Imposible cargar un hecho con una máquina, fecha o causa que no existe
Miembro "Desconocido" (llave −1)	Cada dimensión	Los nulos de la fuente (3.912 turnos, 4.236 operarios) no hacen perder filas en una unión
`NOT NULL`	Llaves y medidas obligatorias	Evita hechos incompletos
`CHECK` **de rango**	Horas ≥ 0, `trimestre` 1 a 4, `hora_key` 0 a 23, `minutos_paro` 0 a 60, `horas_paro` > 0	Rechaza valores imposibles en la propia base
`UNIQUE`	Nombres de dimensiones, `fact_produccion.fila_origen`, `fact_registro_horario (maquina_key, fecha_hora)`	Evita duplicados; la simulación no puede insertar dos lecturas de la misma máquina en el mismo instante
Columnas calculadas (`GENERATED ... STORED`)	`horas_productivas`, `minutos_paro`	El cálculo vive en un solo lugar y no se puede desincronizar
Rango de fechas de vigencia	`dim_meta_velocidad`: `vigente_hasta ≥ vigente_desde`	Mantiene la coherencia de la dimensión de cambio lento
Mínimo privilegio	Usuario `bi_lector`	Los tableros leen, no escriben (ver seguridad)

8.3 Índices y por qué

Las llaves primarias y las restricciones `UNIQUE` ya crean su propio índice. Los demás se definieron según las consultas analíticas más frecuentes:

Índice	Tabla y columnas	Consulta que acelera
`ix_fprod_maquina_fecha`	`fact_produccion (maquina_key, fecha_key)`	Tendencias y comparativos: filtrar una máquina y agrupar por fecha (OEE mensual, año contra año)

Índice	Tabla y columnas	Consulta que acelera
`ix_fprod_fecha`	`fact_produccion (fecha_key)`	Totales por periodo sin filtrar máquina
`ix_fprod_referencia`, `ix_fprod_turno`	`fact_produccion`	Cortes por referencia y por turno
`ix_fparo_paro`	`fact_paro (paro_key)`	**Pareto** y drill-down: agrupar horas por causa
`ix_fparo_maquina_fecha`	`fact_paro (maquina_key, fecha_key)`	Paro de una máquina en un periodo (disponibilidad, MTBF, MTTR)
`ix_fparo_fecha`, `ix_fparo_operario`	`fact_paro`	Cortes por fecha y por operario seudonimizado
`ix_freg_fechahora`	`fact_registro_horario (fecha_hora DESC)`	Grafana: las lecturas más recientes; casi todos sus filtros son una ventana de tiempo
`ix_meta_vigente` (parcial)	`dim_meta_velocidad (maquina_key, referencia_key) WHERE es_vigente`	Buscar la meta vigente de una máquina y referencia; solo indexa las filas vigentes

No se crearon índices sobre cada columna: cada índice extra hace más lenta la carga del ETL y ocupa espacio. Con unas 5.000 jornadas y 16.000 eventos de paro, estos bastan.

8.4 Consultas analíticas

Las 10 consultas están en `sql/consultas/consultas_analiticas.sql`. Cada una responde una pregunta de negocio y usa agregaciones, funciones de ventana o comparativos entre periodos:

#	Pregunta de negocio	Técnica
Q1	¿Qué pocas causas concentran las horas perdidas? (Pareto)	`SUM() OVER ()` y acumulado con `SUM() OVER (ORDER BY ...)`
Q2	¿Cómo evolucionan disponibilidad, rendimiento, calidad y OEE por máquina?	Vista `v_oee_mensual`
Q3	¿Mejoramos frente al mismo mes del año anterior?	`LAG() OVER (PARTITION BY maquina, mes ORDER BY anio)`
Q4	¿Qué máquina rinde mejor y cuál peor cada mes?	`RANK() OVER (PARTITION BY mes ...)`
Q5	¿Cuál es la tendencia de fondo sin el ruido de un mes?	Promedio móvil `ROWS BETWEEN 2 PRECEDING AND CURRENT ROW`
Q6	¿Cada cuánto falla una máquina y cuánto tarda en repararse?	MTTR y MTBF con CTE
Q7	¿Cuánto del paro es evitable?	`FILTER` sobre paro programado y no programado
Q8	Dentro de fallas y ajustes, ¿qué subsistema y detalle pesan más?	`ROLLUP` con `GROUPING()`
Q9	¿Qué días concentran los peores paros?	`ROW_NUMBER()` por máquina
Q10	¿Qué turno rinde más frente a su meta?	Rendimiento contra la velocidad de referencia

Resultados de las consultas (leídos de la base cargada)

Resultados reales de las consultas de `sql/consultas/consultas_analiticas.sql`, generados al construir este documento.

Q1 · Pareto de causas de paro (10 primeras)

Código	Causa	Horas	% del paro	% acumulado
16	Alimentación y aseo de la zona de trabajo y la máquina	2000	23.7	23.7

Código	Causa	Horas	% del paro	% acumulado
5	Ajuste operativo	1814	21.5	45.2
6	Limpieza por derrame operativo	1546	18.3	63.6
17	Pausa activa	713	8.5	72.0
7	Alistamiento de máquina / Cambio de referencia	621	7.4	79.4
10	Paro por ventaja/evacuación	356	4.2	83.6
1	Falla del sistema electromecánico y/o de control	323	3.8	87.4
14	Falta de materia prima	253	3.0	90.4
12	Materia prima defectuosa	227	2.7	93.1
9	Falta de operario	182	2.2	95.3

Q2 · OEE y sus componentes por año (promedio de los meses de las 4 líneas)

Año	Disponibilidad %	Rendimiento %	Calidad (proxy) %	OEE %
2022	87.0	73.4	100.0	63.8
2023	79.8	70.2	99.4	55.2
2024	69.3	84.0	99.0	58.0
2025	67.2	84.4	99.8	56.7

Q4 · OEE promedio por máquina y año

Máquina	2022	2023	2024	2025 (hasta marzo)	Todo el periodo
Vinilos_1	61.8	52.4	49.8	50.3	53.7
Vinilos_2	56.8	41.6	50.3	54.8	49.4
Vinilos_3	66.8	60.6	68.1	62.0	64.7
Vinilos_4	68.4	64.9	63.9	59.5	65.2

Q6 · Fallas electromecánicas (código 01): MTTR y MTBF por máquina y año

Máquina	Año	Fallas	MTTR (h)	MTBF (h)
Vinilos_1	2022	19	0.80	46.2
Vinilos_1	2023	60	0.73	42.9
Vinilos_1	2024	30	0.59	61.0
Vinilos_1	2025	2	0.25	253.2
Vinilos_2	2022	11	0.92	54.6
Vinilos_2	2023	19	0.49	44.7
Vinilos_2	2024	14	0.88	86.2
Vinilos_2	2025	1	0.75	179.2
Vinilos_3	2022	46	0.86	55.6
Vinilos_3	2023	60	0.67	57.8
Vinilos_3	2024	37	0.37	92.4
Vinilos_4	2022	75	0.74	38.2
Vinilos_4	2023	60	0.78	53.4
Vinilos_4	2024	28	0.46	145.4

Máquina	Año	Fallas	MTTR (h)	MTBF (h)
Vinilos_4	2025	2	2.08	363.7

9. Power BI: tablero analitico para la gerencia

Proyecto en formato **PBIP** (carpetas de texto). Se eligio sobre el `.pbix` porque un `.pbix` es un binario: Git no puede mostrar que cambio entre dos commits ni permite fusionar el trabajo de dos personas. Con PBIP el modelo (TMDL) y las paginas (JSON) son texto y se versionan como codigo.

9.1 Como abrirlo

1. Tener la base levantada y el ETL corrido (ver el README principal).
2. En Power BI Desktop: **Archivo > Opciones > Caracteristicas en version preliminar** y activar *Almacenar el modelo semantico con formato TMDL* y *Almacenar informes con formato mejorado de metadatos (PBIR)*. Reiniciar Power BI.
3. **Archivo > Abrir informe** y elegir `powerbi/BI_Vinilos.pbip`.
4. Power BI pide las credenciales de PostgreSQL: pestana **Base de datos**, usuario y contrasena del `.env`. Si ofrece conexion sin cifrar, aceptar (la base corre en tu propio equipo).

Las credenciales **no se guardan en el repositorio**: Power BI las conserva solo en el equipo.

9.2 Que contiene

Conexion: a la base de datos (esquema `dw`), nunca al Excel. Modo importacion. No se cargan `seguridad.operario_pii` ni `calidad`, por lo que ningun nombre real llega al tablero.

Modelo: estrella con 2 tablas de hechos (`fact_produccion`, `fact_paro`) y 8 dimensiones, 13 relaciones de uno a muchos. `dim_fecha` esta marcada como tabla de fechas.

Jerarquias: `Calendario` (anio, trimestre, mes, dia) y `Jerarquia de paros` (area de impacto, codigo, subsistema, detalle).

Medidas DAX (carpetas dentro de `fact_produccion`):

Carpeta	Medidas
1. Basicas	Pacas, Horas programadas, Jornadas, Horas de paro, Eventos de paro, Horas productivas, Pacas por hora programada
2. OEE	Disponibilidad, Pacas validas, Pacas ideales, Rendimiento, Calidad (proxy), **OEE**
3. Paros	Horas paro programado / no programado, % paro no programado, % del paro total, **Pareto % acumulado**, Fallas, MTTR, MTBF
4. Inteligencia de tiempo	Pacas anio anterior, Variacion vs anio anterior (`SAMEPERIODLASTYEAR`), Pacas acumuladas del anio (`TOTALYTD`), OEE anio anterior, Variacion OEE, OEE promedio movil 3 meses (`DATESINPERIOD`)

Las formulas siguen el catalogo: `docs/catalogo_indicadores.md`.

Paginas:

Pagina	Que responde
Resumen ejecutivo	¿Como va el OEE y cual maquina rinde menos? Tarjetas, linea mensual por maquina, componentes y tabla resumen

Pagina	Que responde
Paros y causas	¿Que causas concentran las horas perdidas? **Pareto**, **drill-down** (area > codigo > subsistema > detalle), MTTR y MTBF
Comparativo anual	¿Mejoramos frente al mismo mes del anio pasado? Lineas por anio, matriz maquina x anio, rendimiento por turno

Cada pagina tiene navegador de paginas y segmentadores (anio, maquina, area de impacto). Para bajar por la jerarquia de paros: en el grafico de barras de "Drill-down", activar las flechas de arriba del visual (*Activar modo de profundizacion*) y hacer clic en una barra.

9.3 Si algo no abre o falla

Este proyecto se escribio a mano (sin abrir Power BI), asi que la primera apertura puede mostrar algun error de formato. Copiar el mensaje exacto y corregirlo; los archivos de texto permiten arreglar solo la pieza afectada (un visual, una tabla) sin rehacer el resto.

Notas de interpretacion: el rendimiento puede superar 100 % (la velocidad de referencia es un percentil 90 historico) y la calidad es un proxy; ver los supuestos S3 y S4 del catalogo.

Capturas del tablero

Captura pendiente: Power BI, página Resumen ejecutivo
Guardar como `docs/capturas/powerbi_1_resumen.png` y volver a construir el informe.

Captura pendiente: Power BI, página Paros y causas
Guardar como `docs/capturas/powerbi_2_paros.png` y volver a construir el informe.

Captura pendiente: Power BI, página Comparativo anual
Guardar como `docs/capturas/powerbi_3_comparativo.png` y volver a construir el informe.

10. Grafana: monitoreo casi en tiempo real

Grafana corre en Docker y **se configura solo al iniciar**: fuente de datos, tablero y alerta se cargan desde archivos (*provisioning*). No hay que crear nada a mano.

10.1 Como usarlo

```
docker compose up -d --wait          # levanta PostgreSQL y Grafana
```

Abrir `http://localhost:<GRAFANA_PORT>` (3001 si el 3000 esta ocupado) con el usuario y la contrasena de `GF_SECURITY_ADMIN_*` del `.env`. El tablero esta en la carpeta **BI Vinilos > Monitoreo de lineas de envasado**. Para ver datos moviendose: `simulacion/README.md`.

10.2 Que se carga automaticamente

Archivo	Que hace
`provisioning/datasources/postgres.yml`	Crea la fuente de datos hacia PostgreSQL. Usuario y contrasena vienen de variables de entorno (`.env`), no del archivo.
`provisioning/dashboards/dashboards.yml`	Le indica a Grafana que cargue los JSON de `dashboards/` .
`dashboards/monitoreo_lineas.json`	El tablero exportado, versionado en Git.
`provisioning/alerting/alertas.yml`	La regla de alerta.

Persistencia: el volumen `grafana-data` guarda el estado de Grafana y `pgdata` los datos de la base; `docker compose down` los conserva y `docker compose down -v` los borra.

10.3 El tablero

Panel	Tipo	Responde
Estado actual por maquina	Estado (stat)	¿Que maquinas estan produciendo, con paro corto o PARADAS?
Alertas	Lista de alertas	¿Hay alguna alerta activa?
Pacas por lectura	Serie de tiempo	¿Como evoluciona la produccion?
Minutos de paro por lectura	Serie de tiempo	¿Quien esta parando y desde cuando? (linea de umbral en 30)
Disponibilidad del periodo	Medidor de barras	¿Que fraccion del tiempo estuvo produciendo cada maquina?
Rendimiento frente a la meta	Medidor de barras	¿Producen lo esperado segun su velocidad de referencia?
Horas de paro por causa	Medidor de barras	¿Cuales son las causas del periodo?
Ultimas lecturas	Tabla	Detalle de cada lectura con la causa del paro

Variables del tablero (listas desplegables arriba): `Maquina` y `Turno`, ambas de seleccion multiple. Filtran todos los paneles. El selector de tiempo y el refresco de 5 s son los de Grafana.

10.4 La alerta: "Paro prolongado en maquina"

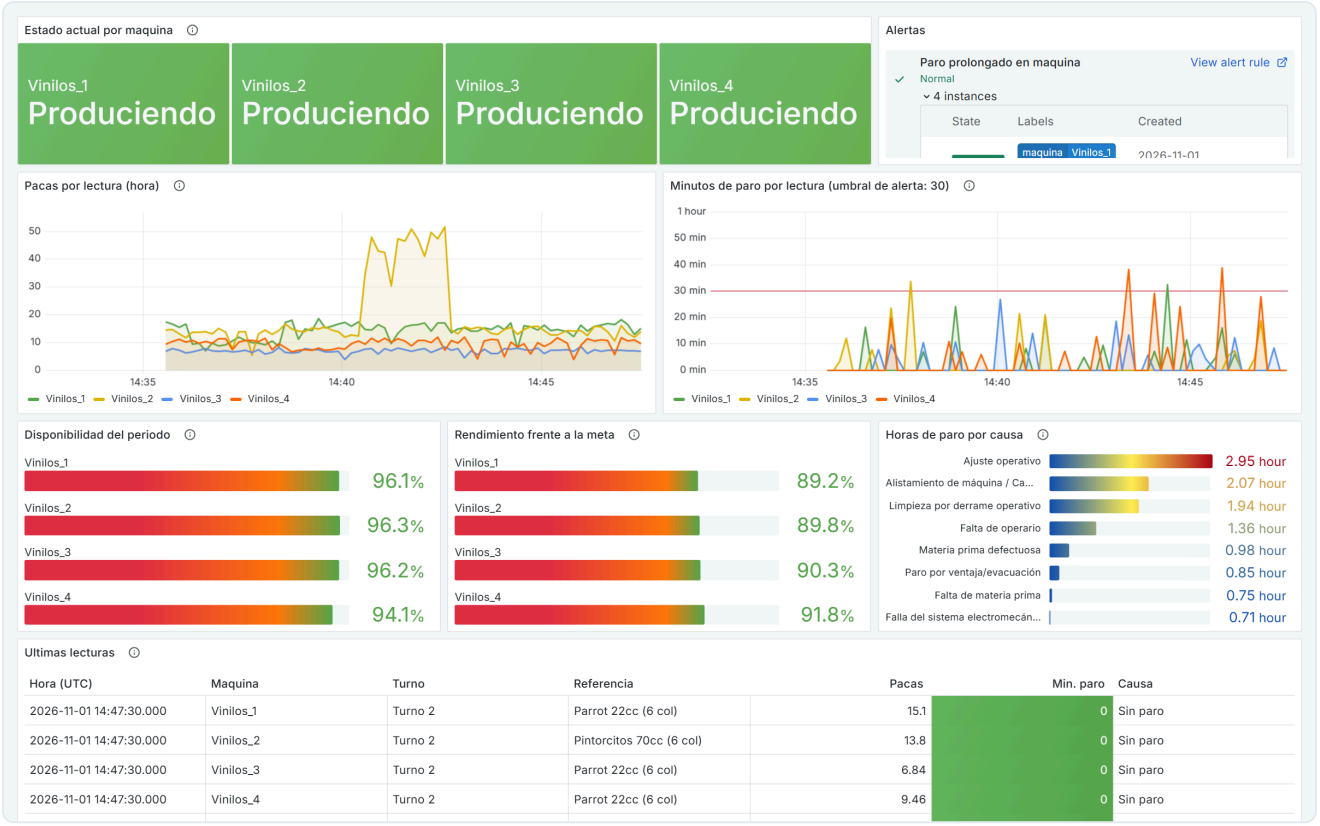
- **Que mide:** minutos de paro de cada lectura (una lectura = una hora de produccion).
- **Cuando salta:** si en las **2 ultimas lecturas seguidas** la maquina tuvo **mas de 30 minutos** de paro. Se evalua cada 10 s.

- **Por que ese umbral:** mas de 30 min de paro en una hora es perder mas de la mitad de la hora (disponibilidad horaria por debajo de 50 %). Los ajustes y limpiezas de 5 a 20 min son normales y no requieren a mantenimiento; exigir 2 lecturas seguidas evita avisar por un paro corto aislado.
- **Una alerta por maquina:** la columna `maquina` de la consulta se convierte en etiqueta, asi que Vinilos_2 puede estar en *Firing* mientras las demas siguen en *Normal*.
- **Notificacion:** no hay correo ni mensajeria configurados (requeririan credenciales); el aviso se ve en el panel "Alertas" y en *Alerting* > *Alert rules*. Propuesta de evolucion: un *contact point* hacia correo o Teams para mantenimiento.

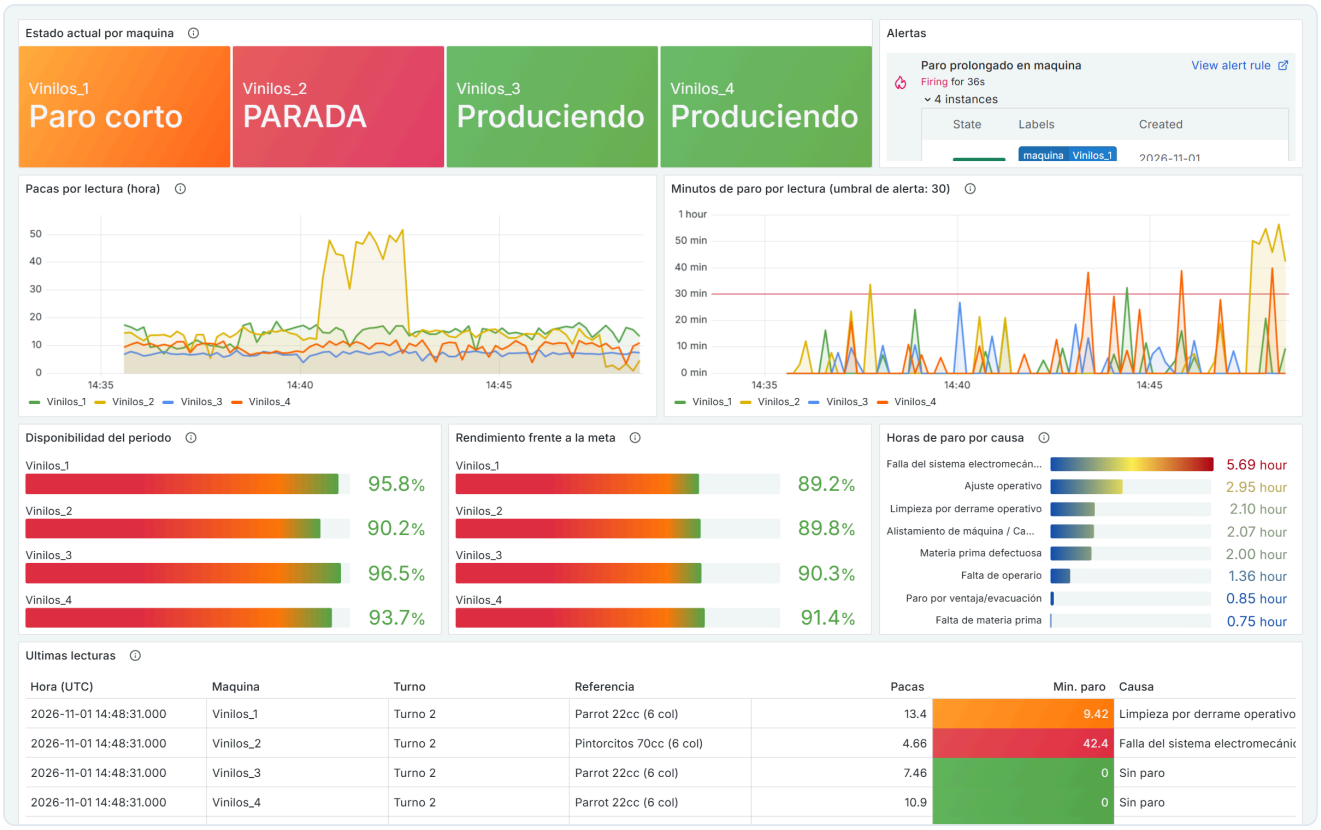
10.5 Seguridad

Sin registro de usuarios nuevos, sin acceso anonimo, fuente de datos de solo lectura (definida por archivo) y credenciales solo en el `.env`, que no se versiona. En produccion se agregarian un usuario de base de datos de solo lectura para Grafana, HTTPS y roles por area.

Capturas del tablero



Estado normal: las cuatro líneas produciendo, sin alertas.



Falla provocada en Vinilos_2: la máquina pasa a PARADA y la alerta «Paro prolongado en máquina» está en Firing.

11. Simulacion de datos hora a hora

Un tablero de monitoreo solo demuestra algo si los datos se mueven. Este script emula las lecturas que llegarian de las lineas y las inserta en `dw.fact_registro_horario`; Grafana las lee y refresca el tablero cada 5 segundos.

11.1 Como correrlo (con la base levantada y el ETL ejecutado)

```
.venv\Scripts\python simulacion\simular.py                       # lecturas cada 10 s, sin limite
.venv\Scripts\python simulacion\simular.py --provocar Vinilos_2  # en OTRA terminal: fuerza una falla larga
.venv\Scripts\python simulacion\simular.py --normalizar          # quita la falla
.venv\Scripts\python simulacion\simular.py --reiniciar           # borra lo simulado y empieza de cero
```

Opciones: `--intervalo` (segundos entre lecturas), `--historial` (lecturas pasadas que crea al empezar, para que el grafico no arranque vacio), `--ciclos` (parar tras N lecturas), `--semilla` (resultados repetibles).

11.2 Que simula

Cada **lectura** equivale a **una hora de produccion** de una maquina. En la demo se emite una cada 10 s en lugar de cada 3.600 s; con `--intervalo 3600` seria en tiempo real.

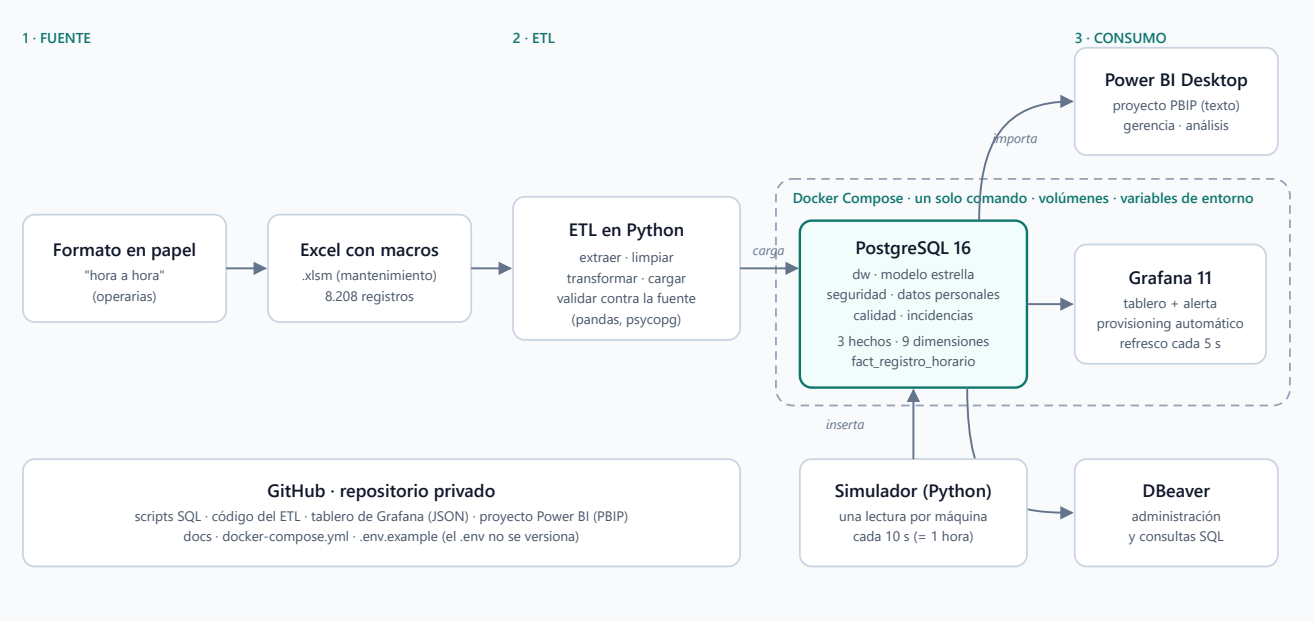
Dato	De donde sale
Pacas de la hora	Velocidad de referencia de la maquina y referencia (`dim_meta_velocidad`), por la fraccion de hora trabajada, con variacion aleatoria alrededor del 90 %
Referencia	Una de las que esa maquina corrio en el historico; cambia de vez en cuando
Paro	20 % de las lecturas, de 3 a 40 minutos; la causa se sortea segun la frecuencia historica de causas **no programadas** (`fact_paro`)
Turno y hora	Calculados con la hora de Colombia (UTC-5): turno 1 de 6 a 14, turno 2 de 14 a 22, turno 3 de 22 a 6
Falla provocada	La maquina elegida reporta de 42 a 58 minutos de paro con causa "Falla del sistema electromecanico" hasta que se normalice

`fecha_hora` se guarda en **UTC**, que es lo que Grafana espera de una columna `timestamp`; la fecha y la hora del modelo (`fecha_key`, `hora_key`) van en hora local.

11.3 Guion para la sustentacion

1. `docker compose up -d --wait` y abrir Grafana (`http://localhost:<GRAFANA_PORT>`).
2. Arrancar `simular.py`: el tablero se mueve solo.
3. En otra terminal: `simular.py --provocar Vinilos_2`. La maquina pasa a **PARADA** en el panel de estado y, tras 2 lecturas seguidas con mas de 30 min de paro, la alerta **"Paro prolongado en maquina"** pasa a *Firing* (se ve en el panel "Alertas").
4. `simular.py --normalizar`: la maquina se recupera y la alerta vuelve a *Normal*.

12. Arquitectura de la solución



12.1 Flujo de datos

Paso	Qué ocurre	Herramienta
1. Captura	Las operarias llenan el formato "hora a hora" en papel; mantenimiento lo transcribe a un Excel con macros.	Papel y Excel (situación actual, sin cambios)
2. ETL	Se lee el Excel, se limpia (duplicados, turnos, subcódigos, referencias), se despivotan los 18 códigos de paro y se carga al modelo. Al final se cuadran los totales contra la fuente.	Python (pandas, psycopg)
3. Almacén	Modelo en estrella en el esquema `dw`; los nombres de operarios en `seguridad`; las correcciones del ETL en `calidad`.	PostgreSQL 16 en Docker
4. Capa analítica	Importa el modelo, calcula OEE, Pareto y comparativos de tiempo para la gerencia.	Power BI Desktop
5. Capa operativa	Lee `fact_registro_horario` cada 5 s, muestra el estado de cada máquina y dispara la alerta.	Grafana 11 en Docker
6. Simulación	Emula las lecturas hora a hora de las líneas para demostrar el tablero y la alerta.	Python

12.2 Decisiones de diseño

- **Power BI y Grafana leen la misma base, no el Excel.** Así las cifras coinciden entre ambos y el Excel deja de ser la fuente de verdad.
- **Todo lo que es servidor va en contenedores** (base y Grafana) para que se levante con `docker compose up -d --wait`, con datos en volúmenes y credenciales en variables de entorno. Power BI y DBeaver corren en el equipo anfitrión y se conectan a los puertos publicados.
- **Grafana no se configura a mano:** la fuente de datos, el tablero y la alerta se cargan desde archivos al iniciar (*provisioning*).
- **Todo es reproducible desde cero** y está versionado: no existe un paso que dependa de clics.

13. Power BI y Grafana: para qué sirve cada uno

Las dos herramientas leen el mismo modelo en PostgreSQL, pero responden preguntas distintas para personas distintas. No son intercambiables.

13.1 Comparativo

	Power BI (capa analítica)	**Grafana** (capa operativa)
Pregunta que resuelve	¿Cómo evolucionó la eficiencia, qué máquina rinde menos y qué causas explican las pérdidas? ¿Mejoramos frente al año anterior?	¿Qué máquina está parada **ahora**, desde cuándo y por qué? ¿Debo llamar a mantenimiento?
Usuario	Alta dirección, jefes de área, coordinador de mantenimiento	Supervisores de producción y técnicos de mantenimiento
Decisión que apoya	Estratégica: inversiones, planes de mantenimiento, programación	Inmediata: reaccionar durante el turno
Horizonte de datos	Meses y años (2022 a 2025)	Últimos minutos y horas
Frecuencia de actualización	Por demanda o programada (diaria o mensual), con la actualización del modelo importado	Cada 5 segundos; la alerta se evalúa cada 10 segundos
Granularidad	Jornada, mes, año; resumen por máquina, turno y referencia	Una lectura por máquina y por hora
Fortaleza	Modelo semántico, medidas DAX, inteligencia de tiempo, drill-down por la jerarquía de paros, narrativa para el comité	Series de tiempo, estado actual, alertas por umbral, variables de filtro, tablero siempre encendido
Indicadores	OEE, disponibilidad, rendimiento, calidad, Pareto, MTTR, MTBF, variación anual	Estado por máquina, pacas por hora, minutos de paro, disponibilidad del periodo
Dónde está en el repositorio	`powerbi/` (formato PBIP)	`grafana/` (JSON y provisioning)

13.2 Por qué no se intercambian

- **Power BI no sirve para vigilar la planta.** Su modelo es importado: se ve la foto del último refresco, no el presente, y no tiene un motor de alertas continuo. Una alerta de paro que llegara con el informe mensual llega demasiado tarde.
- **Grafana no sirve para el comité de dirección.** No tiene un modelo semántico con medidas como "mismo periodo del año anterior" ni jerarquías de navegación, y está pensado para series recientes, no para comparar años ni contar una historia.
- **Se complementan:** Grafana avisa que una máquina lleva dos lecturas seguidas con más de 30 minutos de paro; Power BI explica, con tres años de historia, qué causas son las que más pesan y si el problema es nuevo o recurrente.

13.3 Qué comparten

El mismo modelo estrella, las mismas definiciones de indicadores (`docs/catalogo_indicadores.md`) y la misma base de datos. Por eso la disponibilidad de una máquina en Grafana y en Power BI se calcula igual.

14. Evolución: datos directos desde PLC y SCADA

Hoy los datos nacen en papel, pasan por un Excel y llegan a la base con días de retraso. Si las líneas entregaran sus señales directamente desde los **PLC** o el **SCADA**, el modelo y los tableros se mantendrían; cambiaría solo cómo entran los datos.

14.1 Arquitectura propuesta

```
PLC de cada línea ──► Gateway OPC UA / Modbus ──► Broker MQTT ──► Procesador de flujo ──► PostgreSQL / TimescaleDB ──► Power BI · Grafana
 (contadores, estados,    (convierte el protocolo      (cola de       (agrega por hora,        (mismo modelo estrella +       (sin cambios en
  códigos de paro)         de la máquina)              mensajes)      valida, enriquece)       tabla de eventos)              las definiciones)
```

Componente	Función	Ejemplos
PLC y sensores	Cuentan envases, miden tiempo en marcha y registran el estado de la máquina	Contador de envases, sensor de paro, selector de código de paro en el HMI
Gateway	Traduce el protocolo del equipo a un estándar abierto	OPC UA, Modbus TCP
Broker de mensajes	Desacopla las máquinas de la base, absorbe picos y evita pérdida de datos si algo se cae	MQTT (Mosquitto, EMQX)
Procesador de flujo	Convierte señales crudas en lecturas por hora y eventos de paro, descarta ruido	Python, Node-RED o Telegraf
Base de series de tiempo	Guarda lecturas de alta frecuencia con compresión y retención	TimescaleDB (extensión de PostgreSQL)

14.2 Qué cambia y qué no

Aspecto	Hoy	Con PLC o SCADA
Latencia	Días (transcripción manual)	Segundos
Producción	Pacas por jornada, digitadas	Conteo automático por hora o por minuto
Paros	Código y duración digitados	Inicio y fin medidos por la máquina; el operario confirma solo la causa
Calidad	No se registra	Rechazos contados por inspección en línea
Meta	Se digita y no se guarda	Velocidad nominal configurada en el PLC y guardada como dato
`fact_registro_horario`	Lo llena una simulación	Lo llena el procesador de flujo, con la misma estructura
`fact_produccion` y `fact_paro`	Los llena el ETL desde el Excel	Se alimentan al cierre de cada turno desde los datos del PLC
Dimensiones, medidas DAX, tablero y alerta	—	**Se conservan**

14.3 Beneficios para los problemas encontrados en el diagnóstico

- **Fin de los problemas de calidad de captura:** desaparecen los duplicados, los subcódigos en dos catálogos, los turnos nulos (47 % de las jornadas) y las pacas digitadas como unidades.
- **OEE real:** con velocidad ideal y rechazos medidos, rendimiento y calidad dejan de ser una aproximación.
- **Alertas útiles:** el umbral de 30 minutos se podría reducir a minutos, y agregar alertas por producción por debajo de la meta.
- **Mantenimiento predictivo:** con señales de vibración o corriente de motores y sensores se pueden anticipar las fallas electromecánicas en lugar de reaccionar a ellas.

14.4 Riesgos y cómo mitigarlos

Riesgo	Mitigación
Seguridad de la red industrial (IT y OT)	Segmentar la red, usar OPC UA con certificados y publicar solo hacia afuera, nunca hacia los PLC
Calidad de la señal (falsos paros)	Reglas de filtrado en el procesador de flujo y confirmación del operario
Equipos antiguos sin comunicación	Sensores y contadores añadidos de forma externa, sin tocar el control de la máquina
Volumen de datos	Agregar a hora o minuto para el modelo analítico y conservar lo crudo solo un tiempo limitado

14.5 Ruta de implementación sugerida

1. **Piloto en una línea** (por ejemplo Vinilos_2, la de menor OEE): conteo y estado, comparado en paralelo contra el formato en papel.
2. **Validar** diferencias durante un mes y ajustar las reglas de cálculo.
3. **Extender** a las otras tres líneas y retirar la transcripción manual.
4. **Agregar** calidad en línea y mantenimiento predictivo.

15. Datos personales y seguridad de acceso

15.1 Qué datos personales hay

Dato	Dónde aparece en la fuente	Sensibilidad
Nombre de las operarias y operarios	Columna `Operario` (32 personas distintas tras la limpieza)	Dato personal; permite asociar productividad y paros a una persona
Nombre del personal de mantenimiento	Columna `Personal involucrado` (38 nombres)	Dato personal
Observaciones de paro	Texto libre, puede nombrar a alguien	Posible dato personal

El marco aplicable en Colombia es la **Ley 1581 de 2012** de protección de datos personales: finalidad clara, uso limitado a esa finalidad, acceso restringido y conservación solo mientras sea necesaria.

15.2 Cómo se trató

Principio	Qué se hizo
Minimización	Los análisis de la dirección no necesitan saber *quién* operó, sino la máquina, el turno y la causa. Por eso el modelo analítico no contiene nombres.
Seudonimización	Cada operario recibe un código `OP-nnn` (`dw.dim_operario`). El nombre real vive solo en `seguridad.operario_pii`, en un esquema aparte.
No se carga lo que no se necesita	`Personal involucrado` (nombres del personal de mantenimiento) no se carga al modelo. Tampoco se cargan las observaciones de texto libre.
Los tableros no ven nombres	Power BI no importa `seguridad` ni `calidad`; Grafana lee con un usuario que no tiene permiso sobre esos esquemas.
Fuera del repositorio	El Excel original está en `data/raw/` y el repositorio es privado. No se versiona ningún `.env`.

15.3 Seguridad de acceso

Base de datos: mínimo privilegio

Usuario	Para qué	Permisos
`bi_user` (administrador)	ETL, simulación y mantenimiento	Todos (propietario de la base)
`bi_lector`	Grafana, y recomendado para Power BI	Solo `SELECT` sobre el esquema `dw`. **No puede** leer `seguridad` ni `calidad`, ni insertar, modificar o borrar

Está definido en `sql/init/04_roles.sh` y se comprobó que `bi_lector` recibe `permission denied` al intentar leer `seguridad.operario_pii` o borrar de `dw`.

Grafana

- Sin registro de usuarios nuevos y **sin acceso anónimo**.
- Fuente de datos definida por archivo y de solo lectura (no se puede editar desde la interfaz).
- Credenciales y contraseñas en variables de entorno (`.env`), nunca en los archivos versionados.
- La contraseña del administrador se define en el `.env` y se cambia desde allí.

Power BI

- Las credenciales de la base **no se guardan en el proyecto**: Power BI las pide y las conserva solo en el equipo de quien lo abre.
- Conectar con `bi_lector` en lugar de `bi_user`.
- El archivo `.pbix` publicado y compartido mostraría los datos del modelo, por lo que no incluye nombres de personas.

Repositorio

- Repositorio **privado** en GitHub; el `.gitignore` excluye `.env`, cachés de Power BI y volúmenes.
- Se versiona `.env.example` con valores de ejemplo (`cambia_esta_clave`).

15.4 Qué falta para producción

Lo implementado es adecuado para el proyecto y la demostración. En una planta real se agregaría:

Medida	Por qué
HTTPS en Grafana y conexión cifrada a la base (SSL)	Hoy el tráfico es local y sin cifrar
Autenticación corporativa (Microsoft Entra ID, LDAP) y roles por área	Que supervisores vean solo su línea y la dirección vea todo
Seguridad a nivel de fila (RLS) en Power BI	Limitar qué máquinas ve cada persona
Contraseñas en un gestor de secretos y rotación periódica	Hoy las contraseñas de desarrollo son simples
Copias de seguridad cifradas y política de retención	Conservar solo el tiempo necesario
Aviso y autorización de tratamiento de datos a los trabajadores	Obligación de transparencia de la Ley 1581
Revisión del tratamiento con el área jurídica	Este documento es técnico y no reemplaza una asesoría legal

16. Repositorio y reproducción

Código, scripts SQL, ETL, tablero de Grafana, proyecto de Power BI y documentación están versionados en GitHub: https://github.com/ISFLOWAAA/bi-vinilos (repositorio privado).

Formato de Power BI: PBIP (proyecto en carpetas de texto) en lugar de `.pbix`, porque Git puede mostrar qué cambió entre versiones y dos personas pueden trabajar sin pisarse; un `.pbix` es un binario que no se puede comparar ni fusionar.

No hay contraseñas ni cadenas de conexión con credenciales en el repositorio: el `.env` está excluido y se versiona solo `.env.example`.

Estructura del repositorio

Carpeta	Contenido
`data/raw/`	Fuente original (Excel) y el procedimiento P-MTO-22 en `docs/`
`etl/`	Código de extracción, limpieza, transformación y carga
`sql/`	DDL del modelo, índices y consultas analíticas
`simulacion/`	Script que inserta registros nuevos hora a hora
`grafana/`	Tablero exportado (JSON) y *provisioning* automático
`powerbi/`	Proyecto de Power BI en formato PBIP
`docs/`	Diagnóstico, diccionario de datos, catálogo de indicadores, capturas

Cómo reproducir desde cero

(Se completa a medida que avanza el proyecto)

Requisitos: Git, Docker Desktop (en marcha) y Python 3.11 o superior.

1. Clonar el repositorio.
2. Copiar `.env.example` como `.env` y definir las contraseñas (si los puertos 5432 o 3000 ya están ocupados en tu equipo, cambia `POSTGRES_PORT` y `GRAFANA_PORT`).
3. Levantar PostgreSQL y Grafana con un solo comando: `docker compose up -d --wait` (crea las tablas y los datos fijos solo la primera vez, y Grafana carga solo su fuente de datos, tablero y alerta).
4. Crear el entorno de Python e instalar las librerías: `python -m venv .venv` y `.venv\Scripts\python -m pip install -r etl\requirements.txt`
5. Ejecutar el ETL: `.venv\Scripts\python etl\main.py`. Termina con `TODO CUADRA` y escribe `docs/validacion_etl.md`.
6. Grafana ya quedó levantado en el paso 3 con su fuente de datos, tablero y alerta cargados solos: `http://localhost:<GRAFANA_PORT>` (usuario y contraseña `GF_SECURITY_ADMIN_*` del `.env`). Para ver datos en movimiento: `.venv\Scripts\python simulacion\simular.py`.
7. Abrir el proyecto de Power BI: `powerbi/BI_Vinilos.pbip` (ver `powerbi/README.md`).

Más detalle: ETL · Simulación · Grafana · Power BI.

Documentación

Documento	Contenido
`docs/diagnostico/diagnostico_fuente.md`	Estructura del Excel, problemas de calidad y limitaciones del reporte actual
`docs/catalogo_indicadores.md`	Usuarios, preguntas de negocio, supuestos e indicadores (incluido el OEE)
`docs/modelo_dimensional.md`	Modelo en estrella, granularidad, jerarquía de paros, matriz de bus
`docs/diccionario_datos.md`	Columnas, tipos, llaves, origen y reglas de cada tabla
`docs/validacion_etl.md`	Reglas de limpieza con conteos antes y después, y cuadre de totales

Historial de commits

12 commits en la rama `main`, por autor:

Autor	Commits
Andres Asprilla	12